Mini DDPM Fashion-MNIST 32x32: hasil dan review

Isi folder reports/ (16 gambar), tiap hasil disertai alasan dan cara membacanya

Apa yang dikerjakan

- Model difusi (DDPM) kecil yang belajar memprediksi noise pada gambar Fashion-MNIST yang dipad ke 32x32 dan dinormalisasi ke [-1, 1]. Split 55.000 train / 5.000 val / 10.000 test.
- Dua tantangan dari guidebook: noise schedule (linear dibanding cosine) dan timestep embedding (sinusoidal, dengan pembanding tanpa embedding).
- Jaringan: U-Net kecil (channel dasar 64, multiplier [1, 2], ResBlock GroupNorm, attention di bottleneck), sekitar 3,39 juta parameter. T = 1000, loss MSE antara noise asli dan prediksi.
- Training: AdamW lr 2e-4, batch 128, AMP, grad clip 1,0, EMA 0,999, 50 epoch per run. Sampling memakai DDIM 50 langkah.

Run yang dibandingkan

- linear: schedule linear, ada time embedding.
- cosine: schedule cosine, ada time embedding.
- linear_notime: schedule linear, tanpa time embedding (pembanding).
- Tuning: 6 konfigurasi learning rate dan batch size, 15 epoch, schedule linear.

Temuan utama

- Linear dan cosine dengan time embedding sama-sama menghasilkan pakaian, sepatu, dan tas yang dikenali. Tanpa time embedding hasilnya hampir seluruhnya noise.
- Loss saja tidak cukup: linear_notime punya loss serendah linear (0,0278 dibanding 0,0267) tetapi sampelnya gagal. Loss antar schedule juga tidak sebanding.
- Pada tuning, lr 4e-4 sampai 8e-4 atau batch 64 sedikit lebih baik daripada baseline (sekitar 2,5%). Tiga yang teratas hanya berbeda sekitar 0,2%, jadi belum ada pemenang pasti.
- Belum ada metrik kualitas sampel seperti FID atau KID. Penilaian kualitas saat ini berdasarkan loss dan pengamatan visual.

1. Data: pratinjau train, val, dan test

reports/data/ (train_preview.png, val_preview.png, test_preview.png, summary.json)







Review

Pratinjau ini dipakai untuk memastikan data sebelum training: gambar terbaca benar, orientasi tidak terbalik, dan ada variasi kelas (kaos, celana, sepatu, tas, gaun). Pratinjau ditampilkan 28x28 dengan rentang [0, 1] karena dikembalikan dari tensor model lewat to_display.

summary.json: train 55.000 gambar (430 batch), val 5.000 (40 batch), test 10.000 (79 batch). Nilai piksel tepat di rentang -1 sampai 1 dan tidak ada NaN atau Inf.

Alasan

Kontrak data yang dipakai model adalah [B, 1, 32, 32] di rentang [-1, 1], karena noise yang ditambahkan berdistribusi normal standar dan skalanya harus sepadan dengan data. Split val dibuat stratified (500 gambar per kelas) supaya val loss tidak bias ke kelas tertentu. Train memakai flip horizontal acak (p = 0,5), sedangkan val dan test tidak diaugmentasi.

2. Tabel loss akhir per run

reports/final_loss_table.png dan final_loss_table.csv (dihitung dari checkpoints/<run>/training_log.csv)

Loss akhir per run (50 epoch)

Run	Schedule	Time emb	Epoch	Train loss	Val loss (EMA)	Val terbaik (epoch)
linear	linear	ya	50	0.02672	-	-
cosine	cosine	ya	50	0.04852	0.04590	0.04590 (50)
linear_notime	linear	tidak	50	0.02775	0.02587	0.02587 (50)

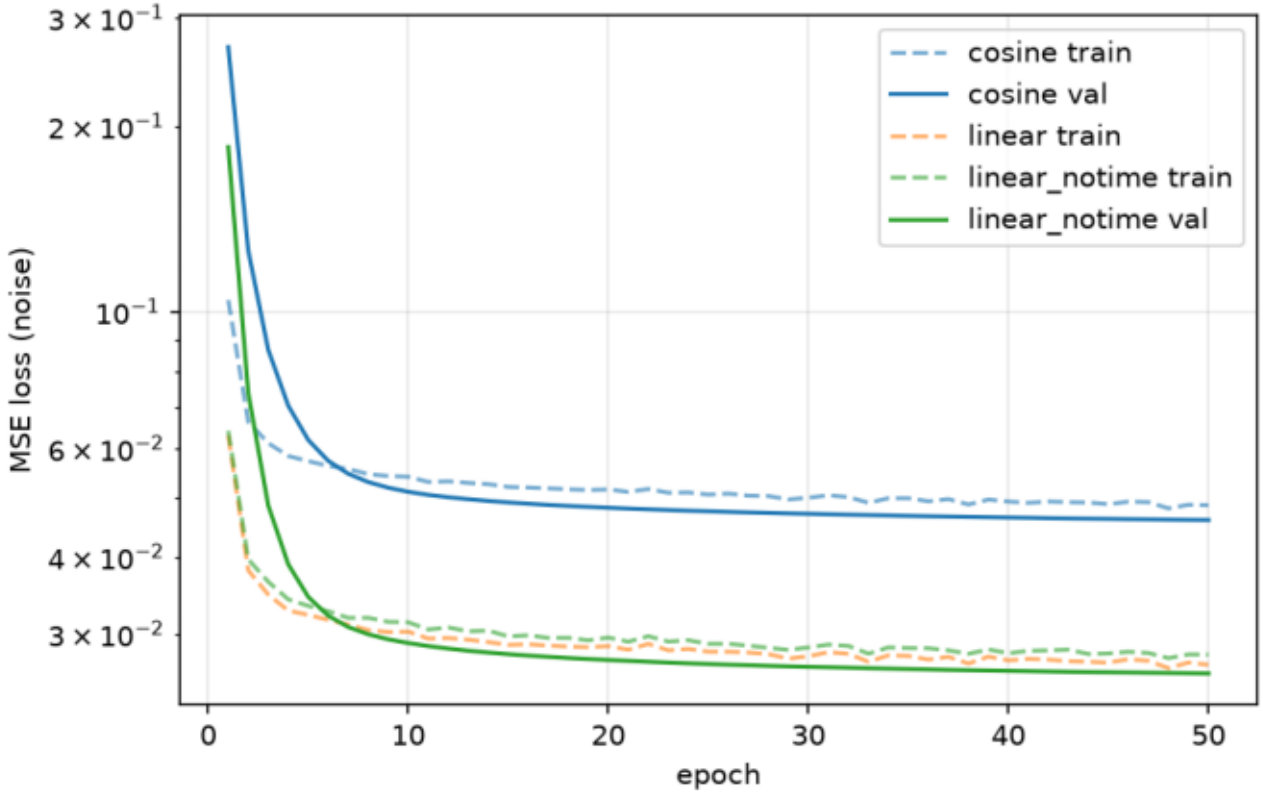
Loss antar schedule tidak sebanding. Run linear tidak punya val loss (log lama).

Review

- Run linear tidak punya val loss karena log lamanya hanya menyimpan satu kolom loss. Angka val-nya sengaja dikosongkan, bukan diperkirakan. Untuk perbandingan val yang adil, run ini perlu dilatih ulang.
- Loss cosine (0,046 pada val) lebih tinggi daripada linear (0,027 pada train) bukan berarti lebih buruk. Dengan cosine, timestep yang diberi bobot lebih banyak adalah yang lebih sulit diprediksi, jadi rata-rata MSE secara alami lebih tinggi. Kedua schedule tidak bisa dibandingkan lewat angka loss.
- linear_notime punya loss yang rendah (0,0259 pada val) padahal sampelnya gagal (lihat bagian 5). Jadi loss rendah tidak menjamin gambar bagus.
- Val loss lebih rendah daripada train loss kemungkinan besar karena val dihitung dengan bobot EMA, sedangkan train loss adalah rata-rata sepanjang epoch dengan bobot yang masih berubah.

3. Perbandingan kurva loss antar run

reports/compare_loss.png



Review

Garis putus-putus adalah train loss, garis penuh adalah val loss (bobot EMA). Sumbu y berskala log.

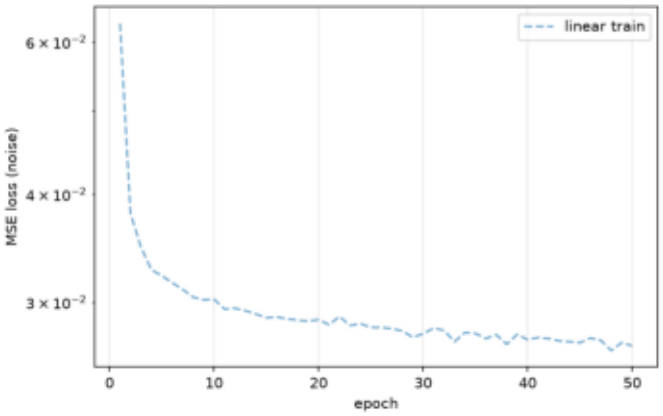
- Semua run turun tajam pada 5 epoch pertama lalu melandai. Sampai epoch 50 kurva masih turun pelan, jadi model belum benar-benar konvergen.
- Train loss linear dan linear_notime hampir menempel. Time embedding hampir tidak mengubah loss, tetapi sangat mengubah kualitas sampel.
- Cosine berada jauh di atas karena definisi bobot timestep-nya berbeda, bukan karena kualitasnya lebih buruk.
- Garis val mulus karena EMA, sedangkan train bergerigi karena rata-rata per epoch dari batch yang diacak.

Alasan

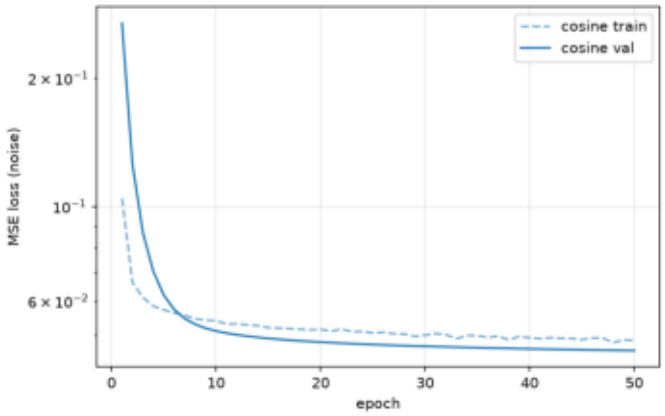
Grafik ini dipakai sebagai bukti bahwa training berjalan wajar (loss turun dan tidak diverge), bukan untuk menentukan schedule terbaik. Run linear hanya muncul sebagai train karena tidak punya val.

4. Kurva loss per run

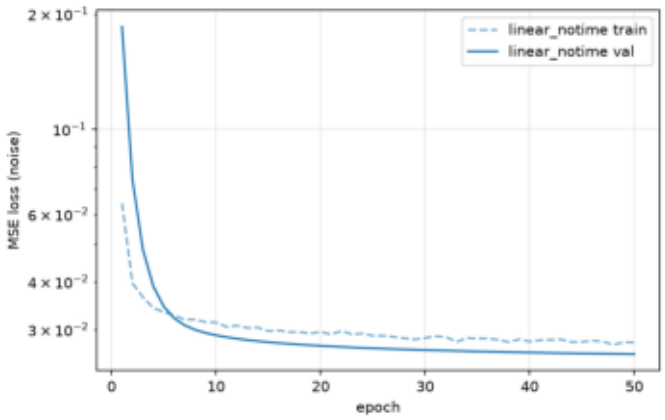
reports/linear/loss_curve.png, reports/cosine/loss_curve.png, reports/linear_notime/loss_curve.png



linear



cosine



linear_notime

Review

- linear: hanya kurva train (garis putus-putus), dari sekitar 0,063 pada epoch 1 menjadi 0,0267 pada epoch 50.
- cosine: train dan val, val turun dari 0,269 ke 0,0459. Val awal sangat tinggi, kemungkinan karena bobot EMA masih dekat inisialisasi di epoch pertama.
- linear_notime: train dan val, val turun dari 0,185 ke 0,0259.

Alasan

Satu gambar per run disimpan terpisah supaya bisa dilampirkan ke laporan tanpa perlu membaca grafik gabungan. Bentuk ketiganya serupa (turun cepat lalu melandai), sehingga perbedaan antar run hanya terlihat jelas pada kualitas sampel, bukan pada bentuk kurva.

5. Grid sampel (DDIM 50 langkah, 64 gambar per run)

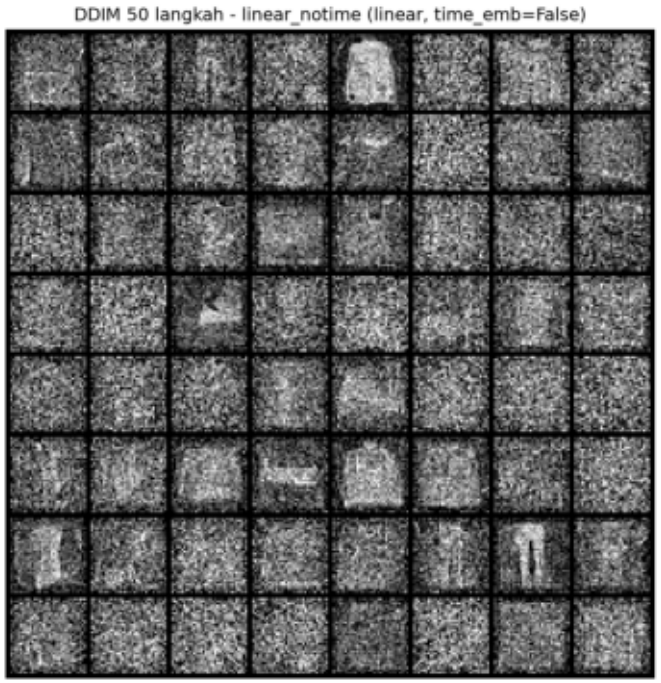
reports/linear/generated_grid.png, reports/cosine/generated_grid.png, reports/linear_notime/generated_grid.png



linear



cosine



linear_notime

Review

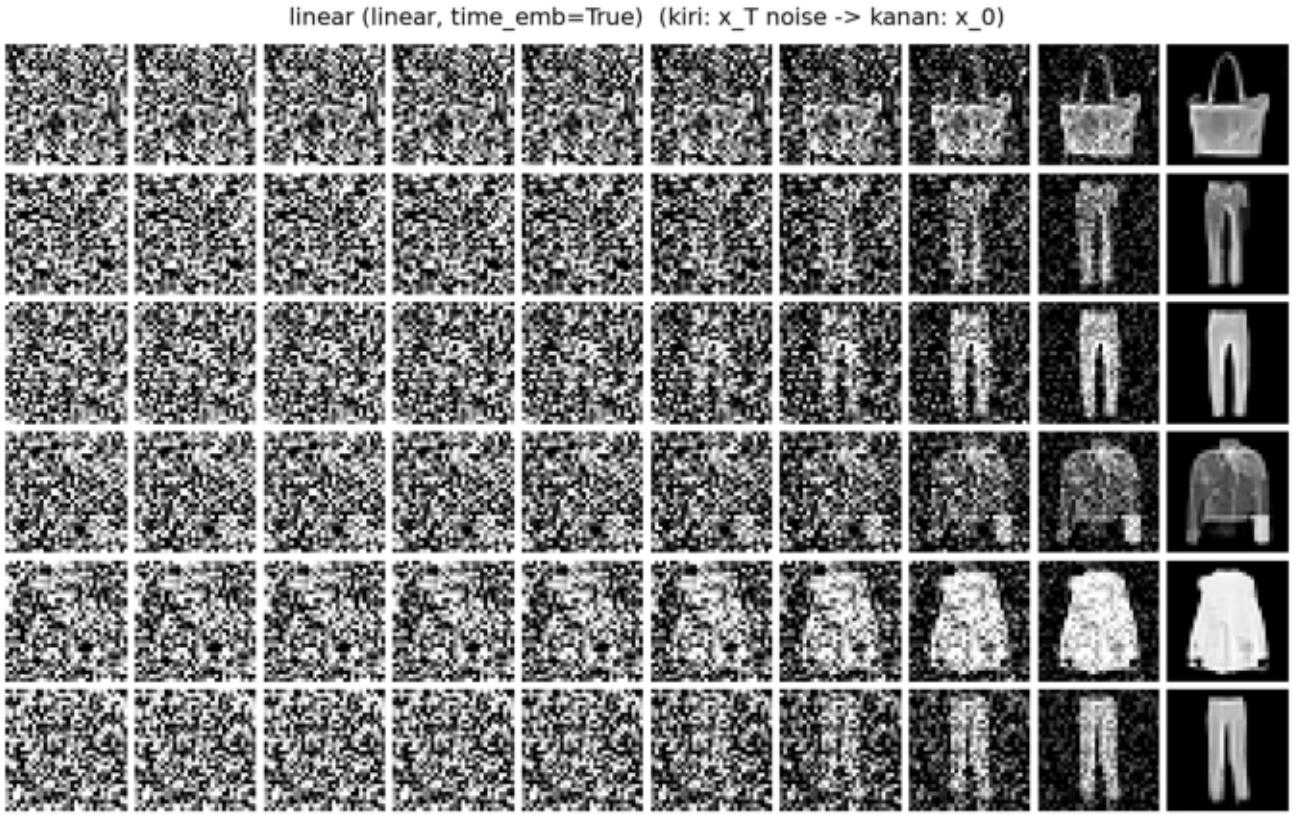
- linear dan cosine menghasilkan bentuk yang dikenali: tas, celana, jaket, kaos, gaun, sneaker, bot, dan sandal. Noise awal sama di semua run, jadi objek di posisi yang sama bisa dibandingkan langsung (misalnya tas dan celana di baris atas).
- Secara visual linear dan cosine mirip. Beberapa sampel masih aneh di keduanya (misalnya baris paling bawah kolom ke-4, bentuk campuran). Tanpa metrik seperti FID kami tidak bisa menyebut salah satunya lebih baik.
- linear_notime hampir seluruhnya noise. Hanya beberapa kotak yang menunjukkan bentuk samar (siluet tas atau celana) dan tidak ada yang jadi gambar bersih.

Alasan

Grid ini adalah bukti paling langsung bahwa model menghasilkan gambar, dan memperlihatkan peran time embedding yang tidak terlihat dari loss.

6. Proses denoising: linear

reports/linear/denoising.png



Review

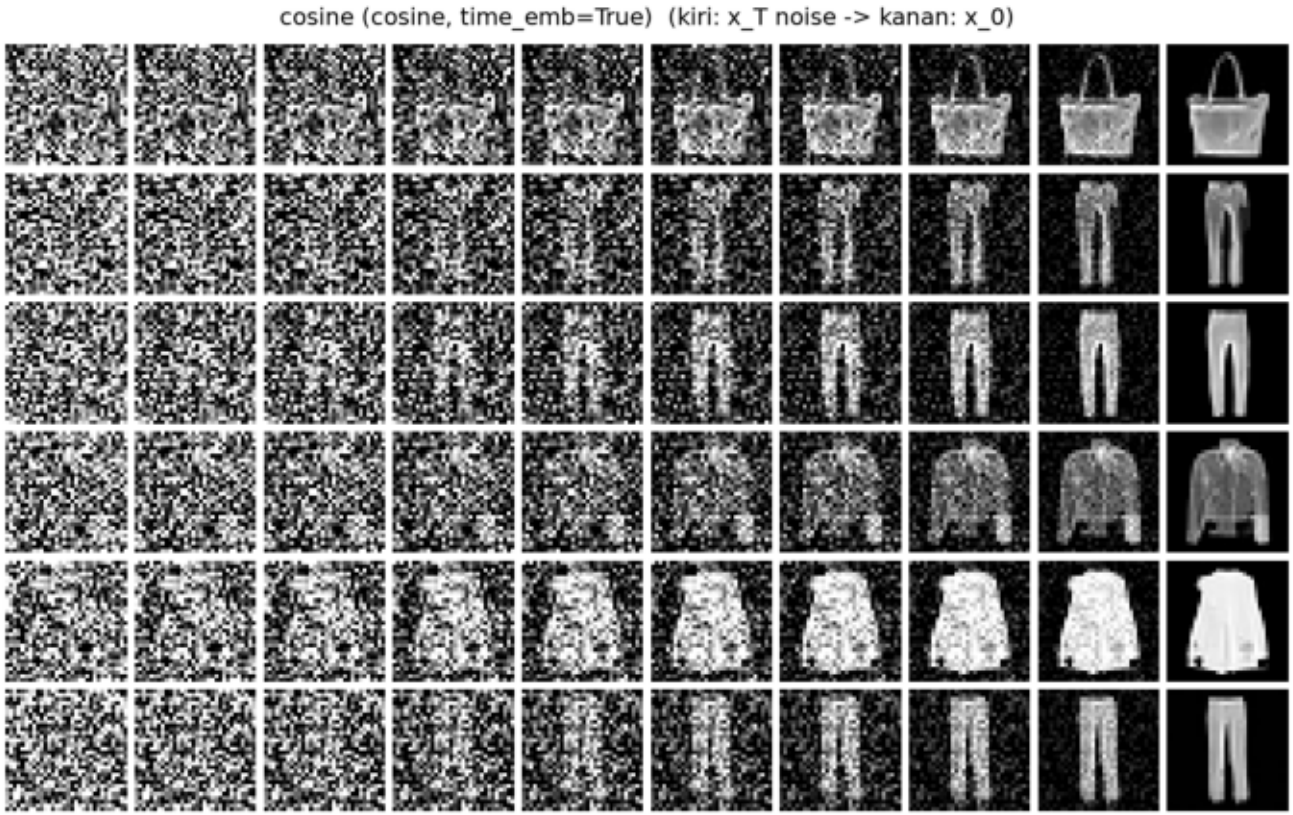
- Tiap baris adalah satu sampel, 10 potongan sepanjang proses sampling: kiri noise murni x_T, kanan hasil akhir x_0.
- Struktur objek (tas, celana, jaket) baru terlihat sekitar kolom ke-7 sampai ke-8, lalu halus dan tajam di kolom terakhir. Kolom 1 sampai 6 hampir seluruhnya noise.

Alasan

Pada schedule linear, sinyal hilang cepat di awal difusi. Akibatnya banyak langkah awal saat sampling terjadi di noise yang hampir murni dan belum terlihat apa-apa. Gambar ini memperlihatkan bahwa proses mundurnya bekerja bertahap (bukan melompat), sesuai yang diharapkan dari DDIM.

7. Proses denoising: cosine

reports/cosine/denoising.png



Review

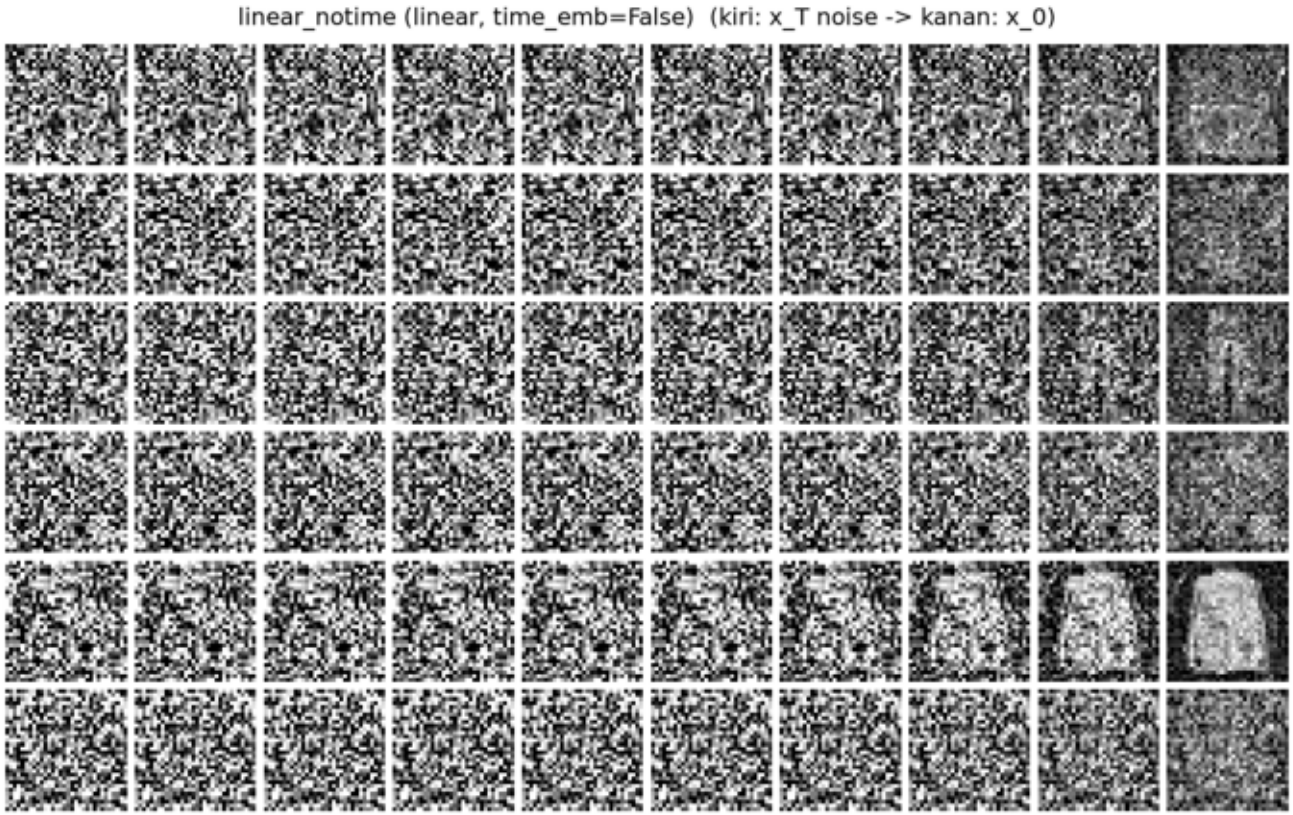
- Format sama dengan linear dan memakai noise awal yang sama, jadi kolom pertama identik.
- Bentuk objek sudah mulai terlihat pada kolom ke-4 sampai ke-5, lebih awal daripada linear. Hasil akhir sama-sama jelas.

Alasan

Schedule cosine menurunkan sinyal lebih landai, sehingga lebih banyak langkah sampling berada pada tingkat noise sedang tempat struktur mulai terbentuk. Ini sejalan dengan motivasi schedule cosine dari Nichol dan Dhariwal. Pengamatan ini dari satu seed dan 6 sampel, bukan hasil pengukuran.

8. Proses denoising: linear_notime

reports/linear_notime/denoising.png



Review

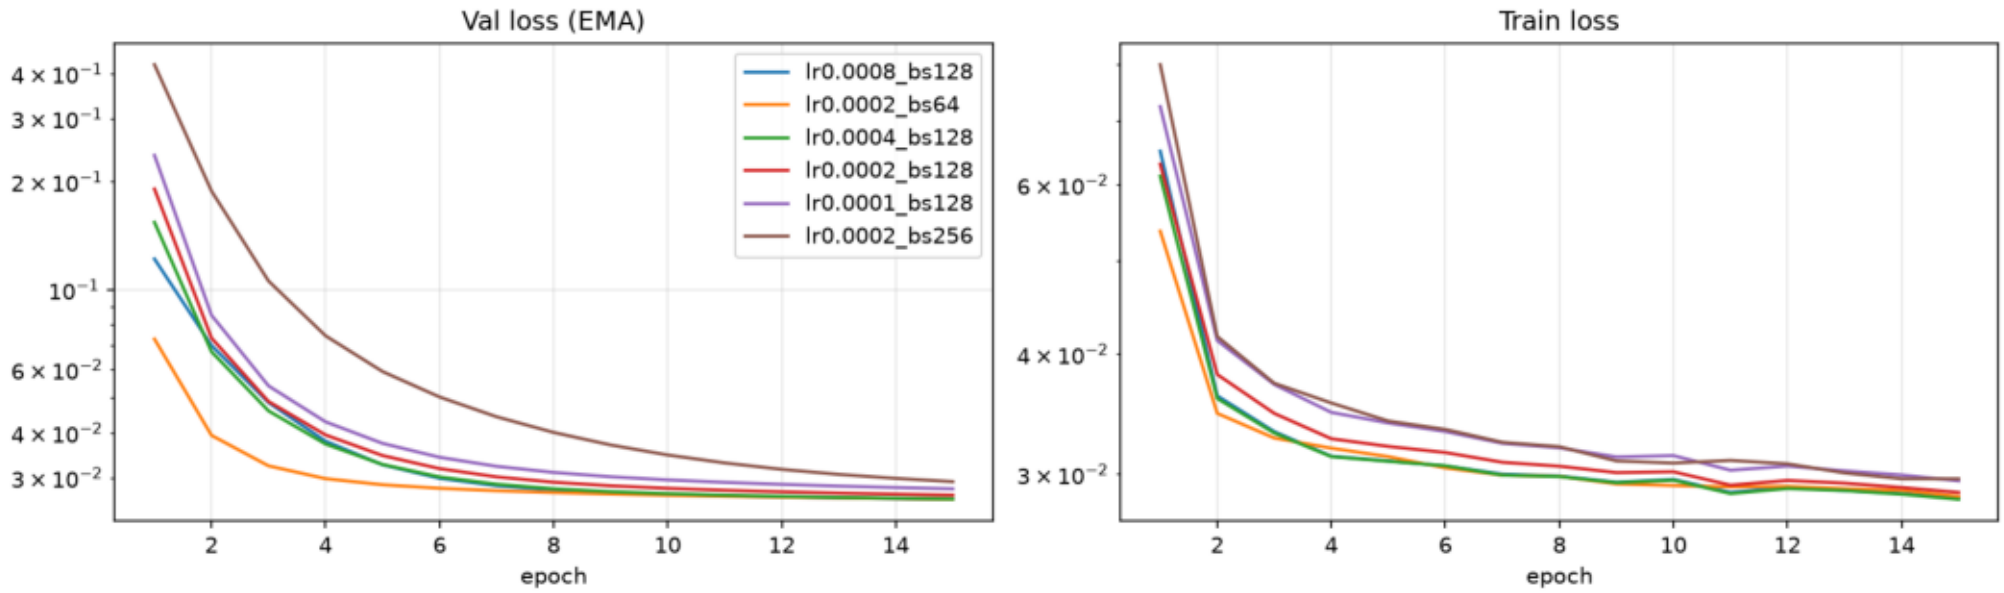
- Hingga kolom terakhir sampel masih berupa noise. Hanya baris ke-5 yang mulai membentuk gumpalan terang seperti bagian atas pakaian, itu pun kabur.
- Tidak ada proses mundur yang menghasilkan gambar bersih.

Alasan

Tanpa time embedding jaringan tidak diberi tahu berada di timestep berapa. Ia harus menebak tingkat noise hanya dari gambar, dan itu sulit pada noise tinggi. Prediksi noise menjadi kurang tepat di awal sampling, dan galat itu menumpuk di langkah berikutnya sehingga gambar tidak pernah bersih. Ini penjelasan yang paling masuk akal untuk hasilnya; kami belum menguji penyebab lain secara terpisah.

9. Tuning: kurva loss 6 konfigurasi

reports/tuning/val_curves.png dan results.csv (schedule linear, time embedding aktif, 15 epoch)

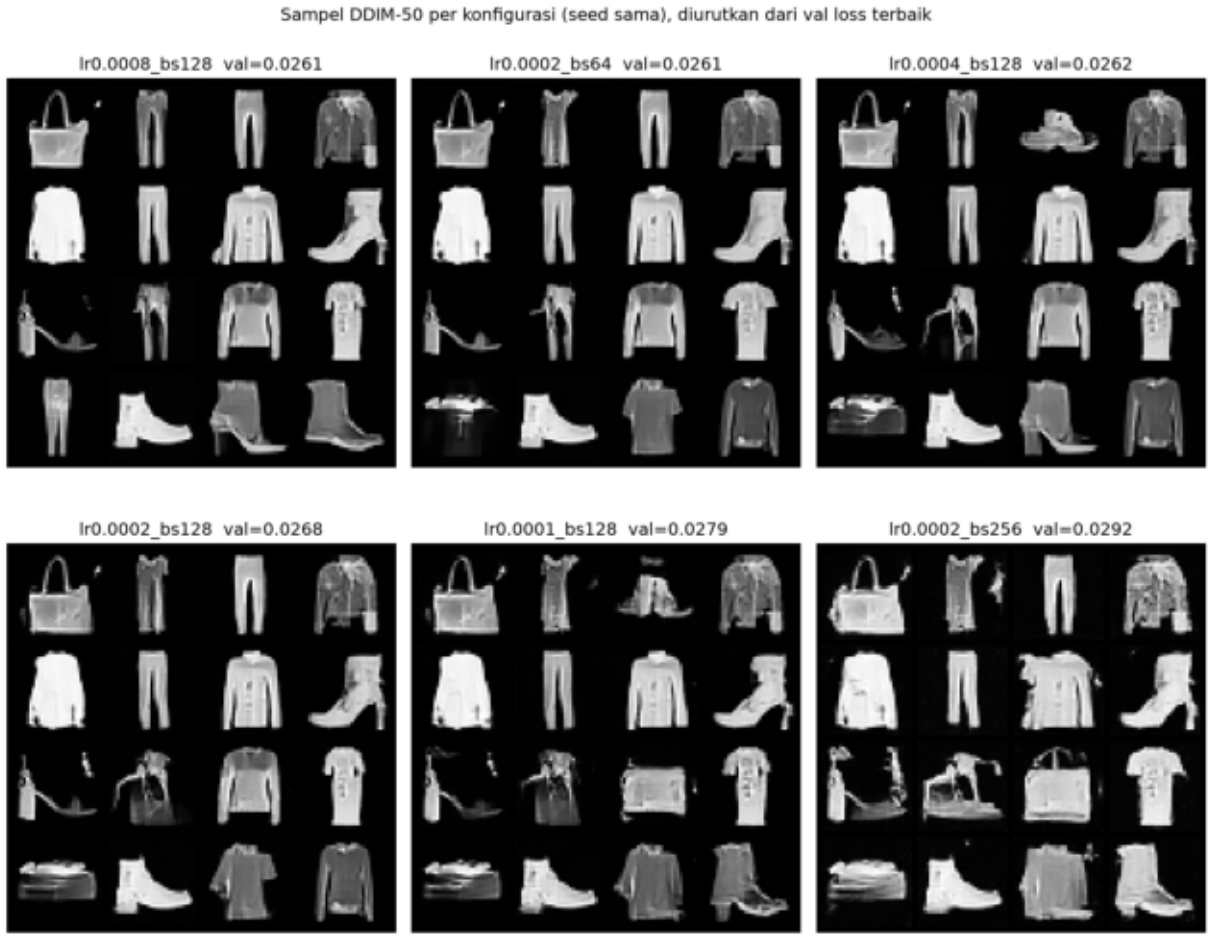


Review

- Urutan val loss terbaik: lr 8e-4 (0,02612), batch 64 (0,02613), lr 4e-4 (0,02617), baseline lr 2e-4 batch 128 (0,02682), lr 1e-4 (0,02794), batch 256 (0,02925). Tiga teratas hanya berbeda sekitar 0,2%, kurang dari yang mungkin muncul karena seed lain, jadi tidak ada pemenang tunggal.
- Learning rate 1e-4 terlalu pelan untuk 15 epoch. Dari 4e-4 ke 8e-4 hampir tidak ada perubahan dan tidak ada tanda diverge.
- Batch kecil lebih baik pada jumlah epoch yang sama. Dugaan kami penyebabnya jumlah langkah update (batch 64 sekitar 12.900 langkah, batch 128 sekitar 6.450, batch 256 sekitar 3.200). Dugaan ini belum diuji dengan jumlah langkah yang disamakan.
- Semua run masih membaik di epoch 15, jadi urutannya bisa berubah kalau dilatih lebih lama. Konfigurasi yang kami pilih untuk dipakai selanjutnya: lr 4e-4 dan batch 128 (lebih konservatif daripada 8e-4, lebih cepat daripada batch 64: 13,4 menit dibanding 16,1 menit).

10. Tuning: sampel per konfigurasi

reports/tuning/samples.png (DDIM 50 langkah, seed sama, diurutkan dari val loss terbaik)



Review

- Perbedaan visual antar konfigurasi halus. Karena seed sama, objek yang muncul hampir sama di tiap panel sehingga bisa dibandingkan satu per satu.
- Panel batch 256 dan lr 1e-4 punya lebih banyak bentuk yang robek atau bercak di sekitar objek. Tiga panel teratas lebih rapi.
- Urutan ini cocok dengan urutan val loss, tetapi hanya 16 sampel per panel dari satu seed, jadi hanya indikasi.

Alasan

Val loss lebih rendah belum tentu gambar lebih bagus, jadi sampel ditampilkan berdampingan sebagai pemeriksaan kedua. Pada eksperimen ini keduanya sejalan.

Catatan: gambar ini dari eksekusi sebelum judul panel diperbaiki, sehingga judul baris bawah sedikit terpotong.

11. Kesimpulan dan keterbatasan

Kesimpulan

- Model DDPM kecil ini berhasil menghasilkan gambar Fashion-MNIST yang dikenali dengan schedule linear maupun cosine, selama timestep embedding dipakai.
- Timestep embedding adalah komponen yang menentukan: tanpa itu loss tampak baik tetapi sampling gagal.
- Untuk learning rate dan batch size, ada sedikit perbaikan dari baseline (sekitar 2,5% pada val loss) dengan lr 4e-4 sampai 8e-4 atau batch 64.

Keterbatasan (perlu disampaikan apa adanya)

- Belum ada metrik kualitas sampel (FID atau KID). Perbandingan linear dan cosine hanya secara visual dan tidak bisa dipakai untuk menyatakan yang mana lebih baik.
- Run linear tidak punya val loss (log versi lama).
- Tuning memakai satu seed per konfigurasi, 15 epoch, dan hanya pada schedule linear. Selisih antar tiga teratas kurang dari variasi yang mungkin muncul karena seed.
- Sampler DDPM ancestral belum diimplementasikan, hanya DDIM 50 langkah.

Langkah lanjut yang masuk akal

- Latih konfigurasi terpilih lebih lama (30 sampai 40 epoch) dan bandingkan dengan run linear awal.
- Ulangi 2 sampai 3 konfigurasi teratas dengan seed lain.
- Tambahkan metrik kuantitatif kualitas sampel dan latih ulang linear dengan val loss.